



الجامعة الافتراضية السورية
SYRIAN VIRTUAL UNIVERSITY

التنقيب في البيانات

الفصل الأول: مقدمة عن التنقيب في البيانات

Information

Technology

Engineering



Powered by:



رقم الصفحة

العنوان

3

1. دوافع التنقيب في البيانات وأهميته

4

2. تعريف التنقيب في البيانات

6

3. مصادر البيانات

16

4. وظائف التنقيب في البيانات

17

5. تمارين

يهدف هذا الفصل إلى:


- التعريف بمفهوم ودوافع التنقيب في البيانات.
- استعراض المصادر المختلفة للبيانات.
- وظائف التنقيب في البيانات.

نعرض في هذه الأملية لمفاهيم التنقيب في البيانات Data mining ودوره في إجرائية اكتشاف المعرفة Knowledge discovery. حيث نستعرض ضمنها المفاهيم المختلفة للتنقيب والتي تساعد في اكتشاف المعارف الجديدة والمهمة والمفيدة والتي قد لا تكون بديهية أو يمكن ملاحظتها مباشرة من خلال استعراض البيانات.

بشكل أساسي سنستعرض طرق التنقيب في البيانات المخزنة في قواعد البيانات بشكلها العلانية Relational database وفي قواعد البيانات المستودعية Data warehouse.

1. دوافع التنقيب في البيانات وأهميته:

ازدادت الحاجة إلى استخدام التنقيب في البيانات في الفترة الأخيرة نظراً للزيادة الكبيرة في حجوم هذه البيانات المتوفرة لدى الشركات والمؤسسات وظهور الحاجة الملحة لاستخراج المعارف الجديدة منها بهدف زيادة فعالية العمل في هذه الشركات والمؤسسات. كما يعتبر استخدام التنقيب نتيجة طبيعية لتطور تكنولوجيا المعلومات التي شهدت تطوراً كبيراً في استخدام نظم إدارة قواعد البيانات وهو ما نتج عنه وجود كميات كبيرة من البيانات المخزنة في نظم المعلومات الخاصة بمختلف الشركات والمؤسسات التي تستخدم هذه النظم (مشارفي، متاجر، مصارف وبنوك، مؤسسات تعليمية، مؤسسات حكومية ...). وبالتالي ظهرت الحاجة لاستخدام هذه البيانات في استخراج معارف وقواعد عمل جديدة يحسن استخدامها من أداء هذه المؤسسات.



الشكل (1-1): إجرائية اكتشاف المعرفة من البيانات.

2. تعريف التنقيب في البيانات:

يقصد بالتنقيب في البيانات عملية استخراج المعارف الموجودة في كميات كبيرة من البيانات، ويقصد بهذه المعارف: المعارف الغير موجودة بشكل واضح وصريح إنما بشكل مخفي وهناك حاجة لأدوات إضافية لاستكشافها. وتشكل عملية التنقيب في البيانات جزء من إجرائية أكبر تسمى إجرائية "اكتشاف المعرفة" knowledge discovery وهي إجرائية تتألف من مجموعة من الخطوات هي كما يظهر في الشكل (1-1):

تنظيف البيانات (data cleaning): ويتضمن إزالة أو استبعاد أو تصحيح القيم الشاذة أو الضجيج من البيانات واستكمال القيم المفقودة عند القدرة على ذلك.

1. تكامل البيانات (data integration): ويتضمن توحيد شكل كتابة البيانات كون هذه البيانات مستخرجة من أكثر من مصدر وتوحيد نمطها ومواصفاتها والمجالات المسموحة لهذه البيانات.

2. انتقاء البيانات (data selection): ويتضمن انتقاء البيانات التي نتوقع أنها مفيدة لتنفيذ إجرائية التنقيب ضمنها.

3. تحويل البيانات (data transformation): تحويل البيانات للشكل الأنسب لتنفيذ التنقيب وهذا يتضمن تجميع البيانات باستخدام توابع التجميع المعروفة لتصبح ملائمة للشكل الذي تطالب عليه في الاستقارات وعمليات التنقيب المختلفة.

4. التنقيب في البيانات (data mining): تطبيق أساليب التنقيب وخوارزمياته المناسبة المختلفة.

5. تقييم النماذج المكتشفة (pattern evaluation and presentation): تقييم نواتج عملية التنقيب باستخدام المؤشرات أو القياسات المتعارف عليها.

6. عرض وتمثيل المعارف الناتجة (knowledge presentation): عرض هذه المعارف باستخدام أساليب العرض المناسبة بشكل مفهوم وواضح للمستخدمين.

تمثل المراحل الأربعة الأولى أشكال مختلفة من المعالجة الأولية للبيانات بهدف إعدادها وتجهيزها لتصبح مناسبة أكثر ما يمكن لتنفيذ عمليات التنقيب عليها وهي خطوات أساسية وهامة لأن التنقيب في بيانات غير مجهزة لتكون صحيحة ومناسبة سيقود إلى نتائج أو معارف خطأ. وتمثل المرحلة الخامسة عملية التنقيب التي سنستعرض في هذا المقرر أساليبها ومجموعة من خوارزمياتها.

وبالاعتماد على ماسبق تكون البنية القياسية لنظام التنقيب في البيانات مكونة من المكونات التالية:

1. مخازن أو مصادر البيانات: تشمل مستودعات البيانات، قواعد البيانات، محتوى الويب، مصادر أخرى كالملفات النصية أو الجداول الالكترونية أو أي مصدر الكتروني آخر يحوي بيانات تفيد في عملية التنقيب.

2. مخدم مستودع البيانات أو قاعدة البيانات: المسؤول عن جلب البيانات التي تتناسب مع متطلبات التنقيب التي يطلبها المستخدم.

3. قاعدة المعرفة: وهي المجال المعرفي الذي يقود إجراءات التنقيب أو إجراءات البحث عن النماذج المفيدة وتقييم هذه النماذج. يمكن أن تشمل هذه المعارف هرمية المفاهيم التي تستخدم لتنظيم الوصفات وقيم الوصفات ضمن سويات مختلفة من التجريد. كما تشمل قاعدة المعرفة أيضاً المعارف السابقة المختلفة للمستخدمين والتي يمكن استخدامها لتقدير أهمية النماذج الجديدة أو المعارف الناتجة عن عملية التنقيب، كما تشمل أيضاً قيود أو عتبات يمكن استخدامها للتقييم.

4. محرك التنقيب في البيانات: وهو المكون الأساسي لنظام التنقيب ويتكون من مجموعة المجتزآت الوظيفية التي تقدم وظائف مثل التصنيف والعنقدة وتحليل الترابط والتنبؤ. وهي ما سنوردها بشكل مفصل في هذه الأملية.

5. مكون تقييم النماذج: يستخدم هذا المكون عادة مقاييس أو معايير مهمة ويتفاعل مع مجتزآت التنقيب لتوجيه أو تركيز البحث عن النماذج المهمة أو المفيدة واستبعاد النماذج الغير هامة، ويوصى هنا وللحصول على النماذج الهامة فقط بزيادة عمليات التقييم قدر الامكان.

6. واجهات الاستخدام: يؤمن هذا المكون للمستخدمين امكانية التواصل والتفاعل مع النظام من خلال مجموعة من الأدوات تساعد المستخدمين في التعبير عن استفساراتهم، ويؤمن كذلك إمكانية التنقيب الاستكشافي بناء على نتائج التنقيب وإمكانية استعراض النتائج بأشكال مختلفة.

من منظور مستودعات البيانات، يمكن النظر إلى التنقيب في البيانات كمرحلة متقدمة من مراحل المعالجة التحليلية للبيانات (Olap) فهو يتجاوز النطاق الضيق للمعالجة التحليلية بأسلوب تلخيص البيانات وذلك من خلال دمج تقنيات أكثر تقدماً لتحليل البيانات. كما توظف أنظمة التنقيب في البيانات مجموعة كبيرة من التقانات والعلوم كقواعد البيانات ومستودعات البيانات وتقانات الإحصاء والتعلم الآلي والحوسبة عالية الأداء والشبكات العصبونية وتمثيل البيانات وتحليل البيانات الزمانية والمكانية وغيرها مما يجعل مجال التنقيب في البيانات من المحالات الهامة والحيوية من بين المجالات الخاصة بنظم المعلومات.

3. مصادر البيانات:

يمكن تنفيذ عمليات التنقيب في البيانات مهما كان مكان تخزينها أي ضمن قواعد البيانات أو مستودعات البيانات أو ملفات يمكن أن تكون مؤقتة التخزين مثل ملفات الفيديو أو البريد الإلكتروني أو حتى البيانات العابرة كالبيانات التدفقية دون الحاجة إلى تخزينها بشكل دائم، وفي هذه الأمثلة نستعرض أهم المصادر وهي قواعد البيانات العلائقية ومستودعات البيانات وقواعد البيانات العملياتية وغيرها.

1.3 قواعد البيانات العلائقية Relational Databases:

نظام قاعدة البيانات ويسمى أيضاً بنظام إدارة قاعدة البيانات database management system أو اختصاراً DBMS وهو يتألف من مجموعة من البيانات المترابطة والمخزنة ضمن مجموعة من الجداول المترابطة مع مجموعة من البرامج للوصول إلى هذه البيانات وإدارتها، تشمل هذه البرامج أيضاً تعريف البنى التي ستخزن فيها هذه البيانات بشكل يسمح بالوصول المتزامن لهذه البيانات من قبل أكثر من مستخدم، وكذلك ضمان استمرارية وجود هذه البيانات بشكل صحيح وآمن وحمايتها ممن ليس له صلاحية الاطلاع عليها أو استخدامها.

قواعد البيانات العلائقية تتضمن مجموعة من الجداول لكل منها اسم وحيد غير قابل للتكرار ضمن نفس القاعدة وله مجموعة من الواصفات (الأعمدة) لكل منها اسم وحيد ضمن نفس الجدول ويحوي الجدول مجموعة من الأسطر التي تمثل البيانات ونسعى هذه الأسطر بالصفوف أو السجلات. ويتميز كل سطر من أسطر الجدول عن غيره بمفتاح يمكن أن يكون مؤلفاً من مواصفة واحدة أو اجتماع مجموعة واصفات. وعادة ما تمثل قاعدة البيانات العلائقية بمخطط كيان - علاقة (Entity-relationship diagram: ERD).

كمثال على قاعدة البيانات العلائقية نعرض المثال التالي:

يتم توصيف قاعدة بيانات علائقية خاصة ببيع المواد الإلكترونية عبر الجداول العلائقية التالية: customer الزبون، item المادة، employee الموظف، و branch الفرع. ويظهر الشكل (1-2) أجزاء من هذه الجداول.

يتكون جدول الزبون من مجموعة من الواصفات تشمل رقم الزبون وهي واصفة مفتاحية أي أن القيمة المخزنة ضمنها غير قابلة للتكرار وتعرف بشكل دقيق كل زبون لهذه الشركة، بالإضافة إلى هذه الواصفة توجد واصفات أخرى منها اسم الزبون، العنوان، العمر، الدخل السنوي، المعلومات الائتمانية والفئة ... الخ.

يتكون جدول المادة من رمز المادة كمواصفة مفتاحية بالإضافة إلى الاسم، المصنّع، الفئة، النمط، السعر، بلد الصنع ... الخ. وكذلك بالنسبة لبقية الجداول.

يمكن أن تستخدم الجداول كذلك في قواعد البيانات العلائقية لتمثيل العلاقة بين عدة جداول أخرى، حيث أن العلاقة بين الزبائن والمواد هي علاقة الشراء، لتمثيل هذه العلاقة ننشأ جدول جديد اسمه مثلاً purchase وهو سيخزن بيانات حول مشتريات الزبائن ويحوي واصفات مثلاً رقم المناقلة (عملية الشراء التي تمت)، رقم الزبون، رقم الموظف الذي نفذ العملية، التاريخ، الزمن، طريقة الدفع، مجموع كلفة المشتريات الخاصة بهذه العملية.

كذلك الجدول قائمة المواد التي اشترها الزبون في هذه العملية item-sold، وجدول works-at التي تحوي معلومات عن مكان عمل كل موظف في الشركة (الفرع الذي يتبع له).

يمكن الوصول إلى البيانات المخزنة في قواعد البيانات العلائقية باستخدام لغات الاستعلام العلائقية مثل لغة SQL الشهيرة، وكذلك باستخدام واجهات استخدام بيانية تحوي عادة قوائم تجمع استعلامات ممكن تنفيذها للحصول على البيانات المطلوبة.

الاستعلامات هنا تسمح باسترجاع مجموعات جزئية من البيانات متوافقة مع الشروط المطلوبة في هذه الاستعلامات مثلاً استعلام لعرض أسماء المواد التي تم بيعها في الربع الأخير في الشركة كلها.

ويمكن أن تحوي الاستعلامات أيضاً عمليات تجميعية تفيد في تنفيذ تلخيص للبيانات وعرضها بأسلوب مختلف حيث تستخدم هنا توابع التجميع المعروفة مثل max ويوجد القيمة العليا و min ويوجد القيمة الدنيا و sum يوجد مجموع عدة قيم، وعادة ما تفيد هذه التوابع في الإجابة على استفسارات أكثر تعقيداً مثل إيجاد مجموع المبيعات الشهرية مجمعة وفق الفرع الذي تمت من خلاله، أو عدد عمليات البيع في شهر محدد مثلاً كانون الثاني، أو الموظف الذي حقق أكبر قدر من المبيعات.

عند استخدام تقنيات التنقيب في البيانات على قواعد البيانات هذه يصبح بالإمكان الإجابة على استفسارات أكثر تعقيداً وقد يكون من الصعب الإجابة عنها بالطرق التقليدية، مثلاً تحليل سلوك الزبائن للتنبؤ بمخاطر الائتمان الذي يمنح لهم وذلك بناءً على أعمارهم ودخلهم السنوي وتسهيلات الائتمان السابقة الممنوحة لهم. كما يمكن أيضاً باستخدام تقنيات التنقيب اكتشاف الانحرافات في المبيعات الفعلية عن المبيعات المخطط لها. وكذلك تحديد العروض الممكن تقديمها للزبائن وفق مشترياتهم السابقة.

وتعتبر قواعد البيانات العلائقية أحد أهم مصادر البيانات والأكثر استخداماً وشيوعاً وهي بالتالي نموذج بيانات رئيسي في دراستنا للتنقيب في البيانات.

customer	Cust_id	Name	address	age	income	Credit_info	Category	...
	C1	Smith sandy	1223 lake ave	31	75000\$	1	3	...
	C2	...						

item	Item_id	Name	Brand	Category	Type	Price	Made_place	Supplier	Cost
	13	Hi-res0tv	Toshiba	High resol	Tv	988\$	Japan	Nikox	600\$
	14	...							

employee	empl_id	Name	Category	group	salary	Commission
	E55	Jones jane	Home entertainment	manager	118.000 \$	2 %
	E56	...				

branch	branch_id	Name	address
	B 1	City square	396 michigan Ave, ...
	B 2	...	

purchases	Trans_id	Cust_id	Empl_id	Date	Time	Method_paid	Amount
	T100	C1	E 55	12/10/2022	15:45	visa	152.652\$
	T200	...					

branch	Trans_id	Item_id	qty	Works_at	Empl_id	Branch_id
	T100	13	1		E 55	B1
	...	...			B 2	...

الشكل (2-1): أجزاء من هذه جداول قاعدة بيانات خاصة بمتجر لبيع القطع الالكترونية.


2.3. مستودعات البيانات Data Warehouse:

بفرض أن الشركة التجارية التي استعرضناها في الفقرة السابقة كانت شركة ناجحة ومشهورة وموزعة جغرافياً على أكثر من منطقة ولكل فرع قاعدة البيانات الخاصة به، فإذا طلبت الإدارة العامة للشركة إجراء تحليل لمبيعات الشركة وفق نمط المواد المباعة وذلك لكل فرع خلال الفترة الزمنية المقابلة للربع الثالث من السنة، الإجابة على هذا السؤال ليست بسيطة خاصة وأن البيانات الضرورية للإجابة موزعة على أكثر من قاعدة بيانات وضمن أكثر من موقع.

امتلاك الشركة لمستودع بيانات سيجعل المهمة أكثر سهولة فمستودع البيانات سيحوي كافة البيانات الموجودة في قواعد البيانات الخاصة بكافة الأفرع واللازمة لتنفيذ عمليات التحليل المختلفة ضمن قاعدة

بيانات واحدة، يتم تصميم مستودع البيانات من خلال مجموعة خطوات تشمل تحديد مصادر البيانات في قواعد بيانات الأفرع المختلفة والمطلوب جلب البيانات منها ثم تنظيف هذه البيانات ومكاملتها مع بعضها وتوحيد شكل تخزينها ثم تحميلها في المستودع، ثم وبشكل دوري أو وفق سياسة الشركة إعادة استخراج البيانات الجديدة وتنفيذ نفس العمليات عليها لتحديث بيانات المستودع كل فترة.

يبين الشكل (3-1) إطار العمل التقليدي لبناء مستودع البيانات:



الشكل (3-1) إطار العمل التقليدي لبناء مستودع البيانات.

وبغرض تسهيل وتسريع عمليات استخراج الإجابات عن الأسئلة المختلفة والتي ماتكون عادة بهدف استخراج المعارف بغرض المساعدة في اتخاذ القرار، يتم تخزين البيانات في المستودع بشكل منظم بما يتناسب مع طبيعة الاستفسارات، حيث يتم تخزين البيانات المرتبطة بموضوع (subject) معين (مثلاً الزبائن، المواد، الموردین ...). ويتم تخزين البيانات بحيث تساعد في تحليل ما يتعلق بهذه المواضيع تاريخياً للاستفادة من ذلك للتخطيط للمستقبل، كما أن التخزين يتم كذلك وفق مجمّع لأننا أثناء عمليات تحليل البيانات نهتم بخلاصة ما حدث على الأغراض الخاصة بالمواضيع التي نحللها.

يتم نمذجة مستودع البيانات عادة كقاعدة بيانات متعددة الأبعاد (multidimensional database) حيث يعبر كل بعد بواصفة واحدة أو أكثر من الواصفات التي تعبر عن مفهوم واحد بشكل تكون هذه الواصفات تمثيل لأشكال مختلفة لهذا المفهوم، على سبيل المثال بالنسبة لمفهوم الزمن يمكن أن تكون هذه الواصفات التاريخ، الوقت، اسم اليوم، الشهر، ربع السنة....، السنة، وبالنسبة لمفهوم مكان البيع يمكن أن تكون المتجر، الشارع، الحي، المدينة، الدولة، القارة طبعاً ووفقاً لطبيعة الوظائف المطلوبة من

مستودع البيانات يتم استخدام واصفة أو مجموعة واصفات لكل بعد وتخزينها بشكل هرمي بغرض تسهيل الانتقال بين هذه الواصفات، كما يتم تجميع البيانات المطلوبة عادة أثناء عمليات التحليل وفق هذه الواصفات كما سنرى لاحقاً. ويتم تخزين البيانات في مكعب بيانات (data cube) متعدد الأبعاد (من بعد واحد حتى n بعد). حيث يوفر هذا المكعب امكانية استعراض البيانات من أكثر من وجهة نظر ويسمح بعمليات الحساب المسبق لتجميع البيانات وفق أكثر من صيغة بحيث يقل الزمن اللازم للرجوع إليها.

مثال:

في مثالنا السابق عن الشركة التجارية، إذا قررنا إنشاء مستودع بيانات يجمع كل مايتعلق بعمليات البيع التي تتم في كافة أفرع هذه الشركة، يمكن إنشاء مكعب بيانات ثلاثي الأبعاد هي:

1. العنوان address المدينة (مع القيم: فانكوفر، تورنتو، نيويورك، شيكاغو)، الدولة (مع القيم: أمريكا، كندا).

2. المادة item صنف المادة (مع القيم: هواتف، حواسيب، أجهزة أمن، أجهزة ترفيه منزلية).

3. الزمن (مع القيم: الشهر (أشهر السنة)، ربع السنة (مع القيم: ربع أول، ثاني، ثالث، رابع).


كل خلية من هذا المكعب ستمثل مجموع قيمة المبيعات وفق قيم الواصفات التي تكون على أبعاد المكعب.

مثال:

فمثلاً القيمة 400 تمثل مجموع المبيعات من أجهزة الأمن في مدينة فانكوفر في الربع الأول (Q1). أين تمثل العلاقة <Vancouver, Q1, security>.

مثال:

نلاحظ من الشكل (1-4) أن البيانات مجمعة وفق أكثر من معيار وأنه يوجد مكعب بيانات مكافئ لكل تركيب من الواصفات التي تمثل الأبعاد (الأبعاد تعبر عن المفاهيم التي نوصف من خلالها الموضوع الذي نبني مستودع البيانات لأجله وهو في مثالنا "كمية المبيعات كنقود"). أي أن المكعب يعبر عن تمثيل متعدد الأبعاد للموضوع الذي نهتم بتحليله وكل مكعب يعبر عن تمثيل مختلف لنفس الموضوع بشكل يتناسب مع الأبعاد الخاصة بهذا المكعب.



الشكل (1-4): مكعب بيانات متعدد الأبعاد.

مثال:

عملية الانتقال من تمثيل إلى تمثيل آخر (من مكعب إلى مكعب آخر) تؤمنها الأدوات التي تقدمها مستودعات البيانات والتي صممت أصلاً لتنفيذ عمليات المعالجة التحليلية للبيانات OLAP، هذه الأدوات سنراها لاحقاً عند الحديث عن مكعب البيانات، من هذه الأدوات مثلاً الأداة Roll-up المستخدمة في عمليات التلخيص وهي في مثالنا تنقلنا من المكعب الذي فيه البعد الخاص بالمكان معبر عنه بأسماء المدن ليصبح التعبير بأسماء الدول، والأداة Drill-down المستخدمة في عمليات التفصيل وهي في مثالنا تنقلنا من المكعب الذي فيه البعد الخاص بالزمن معبر عنه بأرباع السنة (Q1, Q2, ...) ليصبح التعبير بالأشهر (January, February, ...).

بهذا الأسلوب من تنظيم التخزين في مستودع البيانات تصبح البيانات ممثلة بالأسلوب المناسب جداً لصناع القرار حيث تكون البيانات مخزنة بالشكل الذي يرد استعراضها وفقه مما يزيد من فعاليته أثناء تطبيق أدوات التنقيب في البيانات.

تتكون قاعدة البيانات العملياتية بشكل عام من ملف بحيث يمثل كل سجل فيه عملية أو مناقلة واحدة، ويتميز كل سجل برقم مميز ID ويحوي مجموعة الأغراض التي شاركت في هذه العملية أو المناقلة. مثلاً بحالة قاعدة بيانات عمليات تخزين معلومات حول عمليات البيع في متجر يكون السطر عبارة عن رقم العملية وأسماء أو أرقام المواد التي تم بيعها في هذه العملية. ويمكن وجود ملفات أخرى في قاعدة البيانات العملياتية بالإضافة للملف الأساسي وهي مخصصة لحفظ معلومات، بحالة قاعدة بيانات متجر يمكن وجود ملف يحوي بيانات الزبائن، وملف يحوي تواريخ العمليات وملف يحوي معلومات المواد

يبين الشكل (1-5) جزء من قاعدة بيانات عمليات خاصة بعمليات البيع في متجر.

رقم المناقلة / Transation-id	قائمة المواد المباعة في هذه المناقلة / List of items-ids
T100	11,13,18,116
T200	12, 18
...	...

الشكل (1-5): جزء من قاعدة بيانات عمليات خاصة بعمليات البيع في متجر

نلاحظ هنا أن الوصفة List of items-ids فيها أكثر من قيمة (في الحالة العامة العملية قد يُباع فيها أكثر من مادة) وهو ما لا يتناسب مع قواعد البيانات العلائقية، ونسمي هذا النوع من البنى بالبنى "العلائقية المتداخلة". لذلك نخزن قاعدة البيانات من هذا النوع في ملف تسلسلي له صيغة الجدول المبين في الشكل أو في علاقة نظامية لها بنية مشابهة للعلاقة item-sold المبينة في الشكل (شكل العلائقية).

3.3. قواعد البيانات العملياتية Operational Databases:

كمحلل للبيانات الخاصة بالمبيعات يمكن أن أسأل السؤال: ما هي المواد التي اشتراها الزبون ساندي سميث أو ما هو عدد عمليات البيع التي شملت المادة 14؟. هذه الاستفسارات تتطلب مسح قاعدة البيانات العملياتية بالكامل.

يمكن أكثر من ذلك السؤال مثلاً عن المواد التي تباع سويةً. هذه الأنواع من الأسئلة يمكن أن تساعد المسؤولين عن التسويق في جميع المواد التي تباع سوية في مجموعات مما قد يساعد في زيادة المبيعات

أو اعتماد سياسة تقديم عروض للزبائن تزيد من أرباح المتجر. فمثلاً إذا اكتشفنا أن الطابعات تباع مع أجهزة الكمبيوتر فبالإمكان تقديم عروض لبيع نوع محدد من الطابعات ذات السعر المرتفع لبيعها بسعر منخفض على الزبائن الذين يشترون أجهزة كمبيوتر على أمل زيادة المبيعات. عادة لا تستطيع الطرق التقليدية اكتشاف هذا النوع من العلاقات علماً بأنه يمكن عبر استخدام أدوات التنقيب في البيانات مع قواعد البيانات العملياتية اكتشاف هذا النوع منها وهو ما سنراه لاحقاً في هذا المقرر عند الحديث عن قواعد الترافق.

4.3. قواعد البيانات الغرضية العلائقية object relational databases:

صمم هذا النوع من قواعد البيانات على البيانات الغرضية العلائقية object-relational data model وهو تمديد للنموذج العلائقي حيث يوفر نمط معطيات لنمذجة للأغراض المعقدة، ولأن معظم قواعد البيانات الحالية تتعامل مع أغراض معقدة أصبح هذا النوع من قواعد البيانات ضرورياً. يرث هذا النوع من قواعد البيانات مفاهيم من البرمجة الغرضية التوجه حيث يعتبر الكيان entity من النموذج العلائقي غرض object. فإذا نظرنا إلى مثالنا عن شركة المبيعات يصبح الموظف غرض، والمادة غرض.

يتم تغليف البيانات الخاصة بغرض ما مع العمليات التي تتم عليه سوية. وكل غرض يرتبط بـ:

- مجموعة من الواصفات التي توصفه (للموظف: الرقم، الاسم، الفئة، ...).
- مجموعة من الرسائل التي تمكن الغرض من التخاطب مع الأغراض الأخرى.
- مجموعة من الطرائق لكل طريقة نص برمجي مخصص للتعامل مع رسالة حيث يتم تنفيذها عند وصول الرسالة وتعيد الطريقة رسالة عند انتهاء تنفيذها. فمثلاً يمكن كتابة طريقة بقصد استرجاع الصورة الشخصية لموظف هي: الطريقة get-photo(employee) تعيد عند تنفيذها صورة الموظف.

يتم تجميع الأغراض التي لها خصائص مشتركة ضمن صفوف الأغراض، ويكون كل غرض هو منتسخ من صف الأغراض التابع له. يمكن تنظيم الأغراض ضمن هرمية "صف / صف جزئي" بحيث يمثل الصف الخصائص المشتركة لكل الأغراض، فمثلاً يمكن تعريف الصف رجل مبيعات sales-person كصف جزئي للصف "موظف employee" ذو الخصائص name, address, birthdate حيث سيكون للصف رجل مبيعات sales-person صفات أخرى غير تلك الموجودة في الصف employees بالإضافة إلى كافة خصائص الصف employees التي سيرثها منه كونه صف جزئي منه.

يجب تطوير تقنيات التنقيب في هذا النوع من قواعد البيانات بحيث تتعامل مع البنى المعقدة للبيانات والأغراض والهرميات الموجودة بين الصفوف والوراثة فيما بينها وطرائقها.

5.3. قواعد البيانات الزمانية temporal databases:

تخزن قواعد البيانات الزمانية بيانات علائقية مرتبطة بالزمن حيث يكون لبياناتها عادة أكثر من توقيع زمني timestamp ولكلاً منها دلالاته. مثل بيانات المستشفيات المعبرة عن متابعة الحالة المرضية لمرضى وتشمل القياسات المختلفة من ضغط وحرارة.

ويوجد أنواع أخرى مشابهة من قواعد البيانات مثل قواعد البيانات التتابعية sequence databases وقواعد بيانات السلاسل الزمنية time-series databases. الأولى تخزن بيانات تعبر عن أحداث متتالية مع أو بدون ربطها بالزمن بشكل مباشر، مثلاً تسلسل مشتريات زبون أو تسلسل طلب صفحات الوب في جلسة لمتصفح ويب. أما الثانية فتخزن بيانات متتالية لمجموعة واصفات خلال مقاطع زمنية متكررة (ساعة يوم، شهر ...).

تستخدم تقنيات التنقيب مع هذا النوع من قواعد البيانات بهدف اكتشاف تحوّل غرض معين عبر الزمن أو اتجاه التعديل على قيمه، وهذه التطبيقات مفيدة في التخطيط للمستقبل، فمثلاً التنقيب في بيانات المصارف يساعد في التخطيط لدوام الموظفين بحيث يزيد عددهم عند الضرورة بحيث يتناسب مع عدد العمليات المصرفية المتوقعة. كما يمكن استخدام تقنيات التنقيب هنا للتنبؤ بأسعار الأسهم. وفي حالة المثال المعروض سابقاً عن المتجر يمكن التنبؤ بأسعار السلع مستقبلاً. هذا النوع من التنقيب يطلب التعامل مع البعد الزمني على أكثر من مستوى (الساعة، اليوم، الأسبوع، ...).

6.3. قواعد البيانات المكانية spatial databases:

يستخدم هذا النوع من قواعد البيانات عادة لتخزين بيانات مرتبطة بالمكان مثل قواعد البيانات الجغرافية وقواعد بيانات تصميم الدارات المتكاملة وقواعد بيانات الصور الطبية أو الفضائية. يمكن تمثيل البيانات المكانية بتنسيق نقطي. ولهذا النوع من قواعد البيانات تطبيقات واسعة في هندسة المدن أو المناطق السكنية أو المناطق الزراعية.

تستخدم تقنيات التنقيب في هذه القواعد لاكتشاف أنماط توزيع السكان أو التحولات التي تتم على الغطاء النباتي أو تحديد المسارات الأنسب للطرق، ويمكن أن تحوي هذه القواعد بيانات زمانية أيضاً لتصبح زمانية - مكانية ومن أشهر التطبيقات لها تطبيقات الاتصالات الخلوية لمعرفة توزيع الضغط على أبراج الاتصالات كتابع للزمن أو في مراقبة أسراب الطيور أو الحيوانات أثناء تنافلاتها في مواسم الهجرة.

7.3. قواعد البيانات النصية والمتعددة الوسائط text databases and multimedia databases:

تتضمن نصوصاً لتوصيف أغراض قاعدة البيانات، وهي ليست بسيطة مثل الكلمات المفتاحية إنما هي جمل طويلة أو فقرات أو نصوص. مثل مواصفات المنتج، تقارير الأخطاء أو رسائل التحذير. وقد تكون غير منظمة بشكل كبير مثل بعض صفحات الويب وقد تكون منظمة نسبياً مثل البريد الإلكتروني أو بعض صفحات الويب (HTML/XML). وقد تكون منظمة بشكل جيد مثل قواعد بيانات فهرس المكتبة. وعادة يمكن تنفيذ قواعد البيانات النصية المنظمة باستخدام قواعد البيانات العلائقية. من خلال التقيب في هذا النوع من البيانات يمكن اكتشاف أوصاف عامة أو موجزة للمستندات النصية أو الكلمات الرئيسية أو الارتباطات بين مفردات المحتوى. وهنا نجمع بين تقنيات التقيب وتقنيات استرجاع المعلومات. وبالنسبة لقواعد البيانات المتعددة الوسائط فيتم فيها تخزين صور وأفلام وتسجيلات صوتية، وهي تستخدم في تطبيقات التعرف على الصور أو الصوت واسترجاعه.

8.3. بيانات الويب the world wide web:

توفر شبكة الانترنت كمية هائلة من المعلومات وتعتبر تطبيقات التقيب فيها مفيدة كونها خزان بيانات يحوي بيانات قديمة وحديثة تتعلق بالكثير من المواضيع الحيوية التي لا يمكن ذكرها كلها ببساطة، نكتفي بذكر مثال وحيد مستخدم في المساعدة باتخاذ قرارات مرتبطة بالتسويق فمن خلال التقيب يمكن تحديد تسلسل مواقع وصفحات الويب التي يتصفحها المستخدمين وكذلك الأجزاء من الصفحات التي يتركز عليها اهتمامهم وبالتالي يمكن استغلال هذه الأجزاء لوضع الإعلانات التسويقية للمنتجات، وبهدف تحسين التسويق أيضاً يمكن دراسة سلوك الزبون وطريقة تفاعله مع المنتجات لتقديم عروض تسويقية مناسبة له وهو جزء مما يعرف اليوم بنظم التوصية. عملياً التقيب في صفحات الويب في معظم الأحيان يشكل تحدياً كبيراً للمهتمين به لأن البيانات لا تكون متوفرة بشكل "مهيكّل" كما هي عليه في قواعد البيانات المختلفة.

4. وظائف التنقيب في البيانات:

تصنف طرق التنقيب في البيانات ضمن صنفين أساسيين هما التنقيب الوصفي Descriptive data mining والتنقيب التنبؤي Predictive data mining.

1.4. التنقيب الوصفي:

يهدف هذا النوع من التنقيب إلى توصيف البيانات بطريقة مفيدة ودقيقة وموجزة بهدف تسهيل التعامل معها، كأن يتم التنقيب ضمن البيانات الخاصة بزبائن متجر بهدف وضعهم ضمن فئات تضم الزبائن المتشابهين من حيث عاداتهم الشرائية مما يسهل عملية تقديم عروض مناسبة لهم (على مستوى الفئة الواحدة). أو تحديد الارتباطات بين السلع المختلفة التي يوفرها المتجر بغرض تسويقها بشكل مشترك، أو في المجال الطبي رسم الخرائط المعبرة عن توزيع الأمراض مكانياً وزمانياً لربط إنتاج الأدوية أو استيرادها بالحاجة لاستهلاكها. من طرق التنقيب الوصفي التي سنستعرضها في هذا المقرر تحليل العنقدة clustering وإيجاد قواعد الترافق association rules.

2.4. التنقيب التنبؤي:

يهدف إلى التنبؤ بقيم واصفات بالإستناد على بيانات أخرى تاريخية متوفرة لدينا. ومن الأمثلة على هذا النوع من التنقيب التنبؤ بأسعار الأسهم أو السلع بالإستناد إلى الأسعار التاريخية المتوفرة لهذه الأسهم أو السلع. أو في المجال الطبي التنبؤ بالأمراض التي قد تصيب الأشخاص مستقبلاً باستخدام بياناتهم الحالية والبيانات المرتبطة بالأمراض. من طرق التنقيب التنبؤي التي سنستعرضها في هذا المقرر التحليل التراجعي regression والتصنيف classification.

5. تمارين:

التمرين الأول: عدد ثلاثة من أنواع قواعد البيانات.

التمرين الثاني: اذكر نوعين من أنواع التنقيب الوصفي.

التمرين الثالث: ما هي أجزاء إجرائية "اكتشاف المعرفة" knowledge discovery.